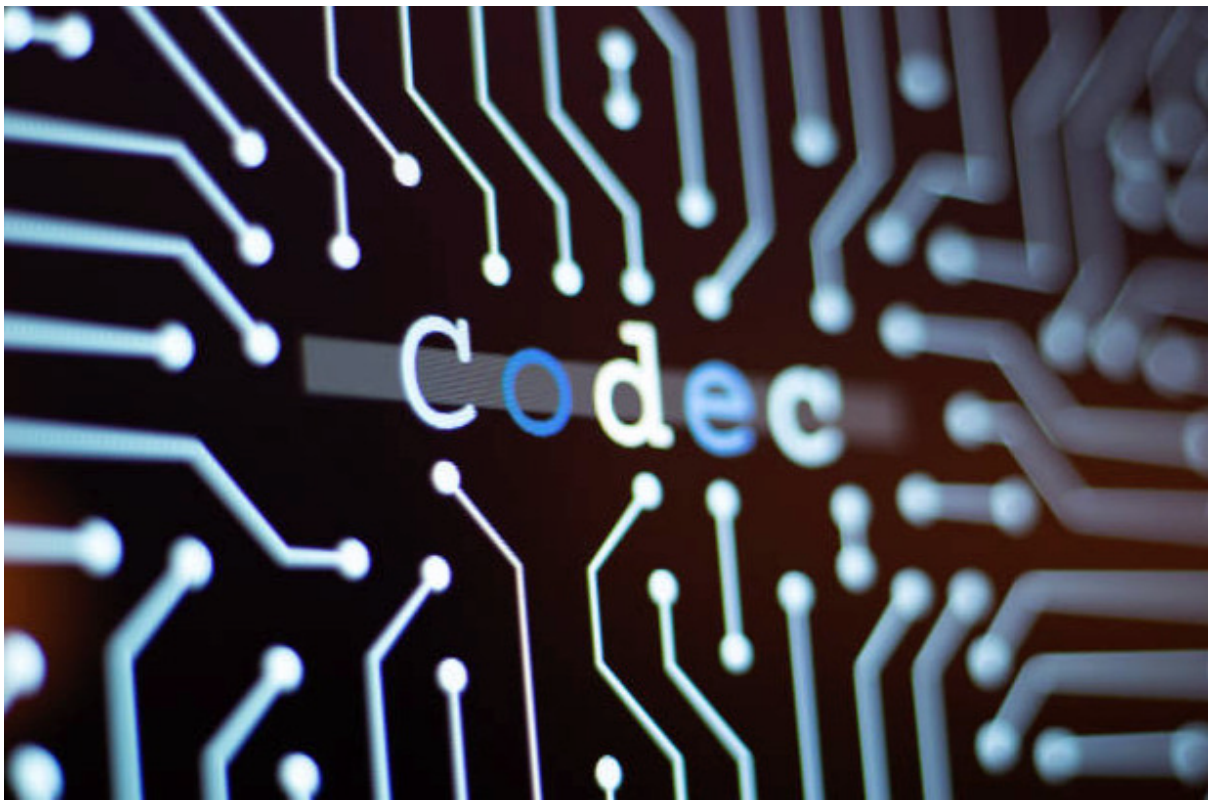
Teoria da Informação

Trabalho Prático nº 2



CODEC

Período de execução: 7 aulas práticas laboratoriais

Ritmo de execução esperado para avaliação:

- Semana 1 a 3: fase de investigação
- Semana 4 a 7: fase de implementação

Formato de Entrega:

- Fase de Investigação: Deverá entregar 1) artigo em formato IEEE (duas colunas) e 2) um Powerpoint preparado para 10 minutos de apresentação com o estado da arte.
- Fase de implementação: Deverá entregar 1) o código de compressão e descompressão e 2) um relatório de suporte.

Prazo de Conclusão:

Aula prática da semana entre 14 e 18 de 16 de Dezembro de 2026

1 Introdução

O objetivo do presente trabalho é a investigação e o desenvolvimento de um encoder e do respetivo decoder para uma fonte de dados. Pretende-se que otimize o algoritmo de compressão e descompressão não destrutivo para a fonte de dados que que lhe será alocada.

Na realização do trabalho poderá utilizar todas as fontes de informação, incluindo modelos de linguagem como o chatGPT ou o Claude, e fontes de código pré-existente. Esse código deverá estar devidamente assinalado e deverá ser entendido pelos autores, caso exista.

2 Fontes de dados

Na aula ser-lhe-á designada uma fonte de informação que deverá utilizar não só no desenvolvimento do algoritmo não destrutivo de compressão, como no respetivo algoritmo de descompressão.

O primeiro passo deverá ser a divisão do conjunto de dados em dados de desenvolvimento (50% do dataset) e em dados de teste (os restantes 50%). A divisão dos dados deverá ser realizada aleatoriamente e por ficheiro, ou seja, um dado ficheiro deverá pertencer ao conjunto de dados de desenvolvimento ou ao conjunto de dados de teste, mas nunca aos dois conjuntos simultaneamente.

As fontes de dados possíveis são as que se listam nas seguintes secções.

2.1 Imagens

Dataset 1 - Textura (https://sipi.usc.edu/database/database.php?volume=textures)

- File format: tiff
- Color space: grayscale
- Dimensions: 512 x 512
- Data type: uint8
- Memory per image: 262 kB
- Nº imagens: 64

Dataset 2 - Aerials (https://sipi.usc.edu/database/database.php?volume=aerials)

- File format: tiff
- Color space: RGB
- Dimensions: 512 x 512 x 3
- Data type: uint8
- Memory per image: 3,1 MB
- Nº imagens: 38

Dataset 3 – Miscellaneous (https://sipi.usc.edu/database/database.php?volume=misc)

- File format: tiff
- Color space: Gray and RGB
- Dimensions: 512 x 512 x 3 – 256 x 256
- Data type: uint8
- Memory per image: 66 KB – 1 MB
- Nº imagens: 39

Dataset 4 – Sequences (https://sipi.usc.edu/database/database.php?volume=sequences)

- File format: tiff
- Color space: Gray
- Dimensions: 256 x 256
- Data type: uint8
- Memory per image: 66 KB, 262 kB
- Nº imagens: 69

2.2 Textos

Dataset 1 – The Canterbury Corpus (https://corpus.canterbury.ac.nz/descriptions/#cantrbry)

- Files format: diverse (4 txt files)
- Nº files: 11
- Memory: 125 KB – 482 KB (for txt)

Dataset 2 – The Artificial Corpus (https://corpus.canterbury.ac.nz/descriptions/#artificl)

- Files format: txt
- Nº files: 4
- Memory per audio: 1byte – 100 KB

Dataset 3 – The Large Corpus (https://corpus.canterbury.ac.nz/descriptions/#large)

- Files format: txt (2 files)
- Nº files: 3
- Memory per audio: ~2.5 MB – 4.6 MB

Dataset 4 – The Calgary Corpus (https://corpus.canterbury.ac.nz/descriptions/#calgary)

- Files format: -
- Nº files: 14
- Memory per audio: 21.5 KB – 768 KB

2.3 Biosinais

Dataset 1 – ECG compression (https://physionet.org/content/cdb/1.0.0/)

- File format: .dat
- Leads: 2
- Sampling rate: 250 Hz (20.48 s)
- Resolution: 12 bits
- Memory per record: 15 KB
- Nº records: 168

Dataset 2 – ECG arrythmia (https://www.physionet.org/content/mitdb/1.0.0/)

- File format: .dat
- Leads: 2
- Sampling rate: 360 Hz (30 min)
- Resolution: 11 bits / 10 mV range
- Memory per record: 2 MB
- Nº records: 48

3 Trabalho

O trabalho encontra-se estruturado em duas fases.

A primeira fase é uma **fase de investigação** em que irá investigar as características da fonte de dados que lhe foi alocada e irá elaborar uma análise do estado da arte dos algoritmos de compressão e descompressão não destrutivos aplicáveis à sua fonte.

Na segunda fase do trabalho irá elaborar um pipeline de algoritmos que servirão de encoder (compressor) e o respetivo decoder (descompressor), fundamentando as suas opções usando uma análise teórica e uma análise estatística.

Fase de investigação

1. 📻 Descarregue a fonte de dados que lhe foi atribuída.
2. 📻 Escreva um código numa linguagem à sua escolha que 1) divida os ficheiros em ficheiro de desenvolvimento e 2) ficheiro de teste. Observe que 50% dos dados deverão ser de desenvolvimento e 50% dos dados deverão ser de teste.
3. ✍ Realize uma análise da entropia da sua fonte de dados, das possibilidades de agrupamento e predição dos seus dados. Para o efeito deverá usar somente os dados de desenvolvimento.
4. ✍ Realize o levantamento do estado da arte dos encoders/decoders não destrutivos aplicáveis à sua fonte de dados.
5. ✍ Elabore um relatório no formato IEEE/duas colunas e máximo 4 páginas, contendo uma descrição das suas análises e conclusões. Poderá encontrar os Templates no seguinte link: https://www.ieee.org/conferences/publishing/templates.
6. ✍ Elabore uma apresentação powerpoint sobre o trabalho realizado no ponto anterior de 10 minutos para partilha na aula.

   A entregar:
   - Relatório elaborado em 5)
   - Powerpoint elaborado em 6)

Fase de implementação

7. ✍ Proponha quatro pipelines de codificação e descodificação da sua fonte de dados, justificando teoricamente o seu racional. Observe que as pipelines não precisam de ser completamente diferentes em todos os seus sub-módulos.
8. 📻 Implemente as pipelines de compressão e descompressão, e analise o respetivo desempenho avaliando a significância estatística. Sugere-se o

seguinte artigo para orientar a escolha do teste estatístico apropriado: https://di.aerzteblatt.de/int/archive/article/74893 [1]

9. 📻, ✍ Realize um estudo de ablação[2] da pipeline com melhor desempenho, indicando o ganho de cada etapa do seu pipeline e analisando a relevância estatística da mesma. Observe que o estudo deverá integrar os efeitos decorrentes do overhead relativo ao armazenamento de estruturas de dados necessárias à descompressão dos dados (por exemplo, árvores de Huffman, etc.).
10. 📻 Elabore a seguinte API
    a. Encode (filename_input, filename_output)-> deverá comprimir o ficheiro de nome filename_input, produzindo o ficheiro comprimido filename_output. Elabore um programa que comprima um ficheiro usando a sua API. A sintaxe deverá ser

       encode *NomeficheiroEntrada NomeFicheiroSaída*

    b. Decode (filename_input, filename_output)-> deverá descomprimir o ficheiro o ficheiro de nome filename_input, produzindo o ficheiro comprimido filename_output. Elabore um programa que comprima um ficheiro usando a sua API. A sintaxe deverá ser

       decode *NomeficheiroEntrada NomeFicheiroSaída*

11. ✍ Elabore um relatório no formato IEEE/duas colunas e máximo 6 páginas, contendo uma descrição dos resultados obtidos e das suas conclusões. Poderá encontrar os Templates no seguinte link: https://www.ieee.org/conferences/publishing/templates.

A entregar:

- Relatório elaborado em 11)

---

[1] J.-B. du Prel et al.,*Choosing Statistical Tests, Deutsches Arzteblatt, 107(19):343-348, 2010. doi: 10.3238/arztebl.2010.0343*

[2] Um estudo de ablação é um método de investigação utilizado para compreender o contributo de componentes individuais para um sistema complexo, removendo-os, alterando-os ou desativando-os sistematicamente, um de cada vez.

Como funciona

- **Medição de referência (baseline):** Teste o sistema completo com todos os componentes ativados e registe o seu desempenho.
- **Remoção (ablação):** Retire uma única funcionalidade, camada, módulo ou parâmetro.
- **Reavaliação:** Teste o sistema modificado exatamente nas mesmas condições.
- **Comparação:** Meça a variação do desempenho para perceber a importância que esse elemento específico tinha.

- API e código fonte elaborado em 10)